DATA FEST 2023

20.05.2023 - 04.06.2023

Тема доклада:

Создание синтетического датасета для SFT LM на задачи суммаризации вакансий

Спикер:

Никита Венедиктов



Познакомимся?



Магистрант AI Talent Hub ITMO

Сейчас НЛПишник в биоинформатическом стартапе Deeploid

Раньше разрабатывал системы для телекома в компании Keysight Technologies

В команде работа.ру участвую в улучшении сервиса по суммаризации вакансий

Никита Венедиктов

VİTMO AI TALENT HUB

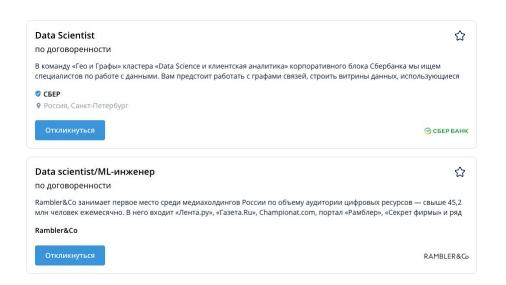
работа.ру

Бизнес-гипотеза



Команда улучшает сервис суммаризации вакансий → повышается конверсия

Решили делать это на основе дообучения разных LLM







Процесс обучения

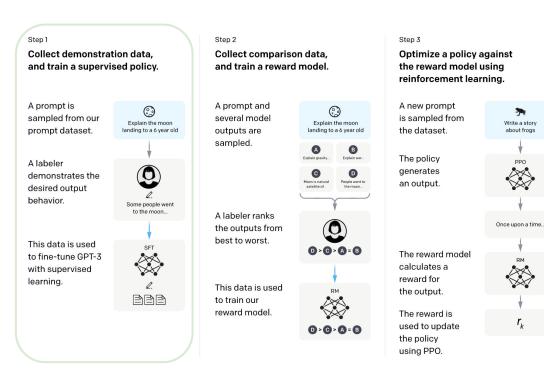
Phase 1. Pretraining for completion

Phase 2. Supervised finetuning (SFT) to summarize vacancies

Phase 3. RLHF

3.1. Reward model (RM)

3.2. Finetuning using the reward model



about frogs



Хватит ли RLHF? Не полетело

Step 2

Collect comparison data, and train a reward model.

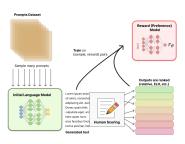
A prompt and several model outputs are sampled.

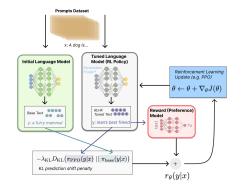


A labeler ranks the outputs from best to worst.

This data is used to train our reward model.







Своими силами, немного дообучим и дадим уже пользователям пользователям возможность ранжировать выдачи модели

-неа



- Особенности предобучения (новости, статьи)
- HR домен
- Галюцинации

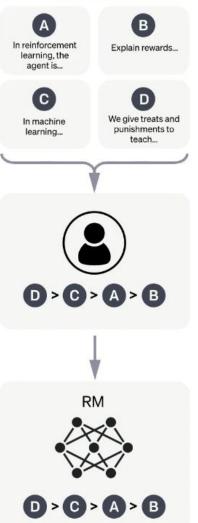


Итоговое решение

- 1. Выбор трансформера (mBART, T5, GPT)
- 2. Синтезируем датасет для адаптации под наши задачи
- 3. Этап Supervised finetuning (SFT)
- 4. RLHF используя модель с 3го этапа генеририруем и первый раз руками размечаем датасет для reward модели 2-3к саммари
- В продакшн и далее используем отклики пользователей для формирования большого датасета обучения reward модели
- 6. Подводим итоги

Важно что мы не сразу в автоматический продакшн

А сначала предложим работодателям несколько вариантов, чтобы выбрали сами и помогли нам





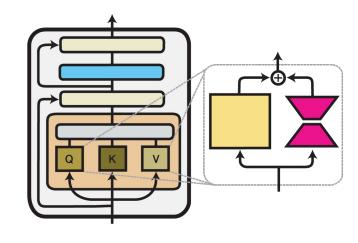
Синтезировать датасет для SFT

Supervised finetuning (SFT) позволяет сначала адаптировать модель под наши задачи

(вешаем на LLM Lora-адаптер для нашего домена)

но для этого нужен датасет

Датасет вакансий есть, осталось его изучить и найти оптимальный метод суммаризации





Особенности вакансий — проблемы?

- проблема в экстрактиции сути истории компаний
- невозможность ранжирования предложений в вакансии однострочник
- проблема в точности экстракции если прям ладненько, но много
- надо было адаптировать предобработку много цифр
- нарезать маркированные списки на предложения

Слова, словосочетания, предложения?

Потом попросим LLM их перефразировать и будет меньше галлюцинаций

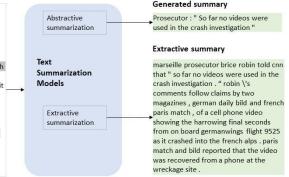
Чем их вытягивать из текста?



Суммаризация — база

Input Article

Marseille, France (CNN) The French prosecutor leading an investigation into the crash of Germanwings Flight 9525 insisted Wednesday that he was not aware of any video footage from on board the plane. Marseille prosecutor Brice Robin told CNN that " so far no videos were used in the crash investigation . " He added, " A person who has such a video needs to immediately give it to the investigators . " Robin\'s comments follow claims by two magazines, German daily Bild and French Paris Match, of a cell phone video showing the harrowing final seconds from on board Germanwings Flight 9525 as it crashed into the French Alps . All 150 on board were killed. Paris Match and Bild reported that the video was recovered from a phone at the wreckage site. ...



Автоматическое создание краткого содержания

Экстрактивная — это когда для суммаризации используются кусочки оригинального текста в том виде, как они были написаны изначально.

Абстрактивная — это генеративная модель, которая создает абсолютно новый текст, где могут содержаться слова, которые не встречались в оригинальном тексте.

В сервисах ты настраиваешь, количество слов, токенов, предложений

Или соотношение вход к выходу



Абстрактивная

Нейронные подходы к абстрактной суммаризации концептуализируют задачу как (seq2seq или text2text)

И сразу приходят в голову решение – трансформеры

А именно функция саммарайз. Но вот только есть свои приколы)

Тяжелые, галюцинации и "неправильный" эттеншн из-за особенностей предобучения



Нас таким не запугать

Тяжесть этим — бьем этими приемами (Квантизация, Прунинг, Дистилляция)

Кривые результаты из-за особенностей обучения — плохо с вакансиями работает дообучения — бьем SFT + RLHF — но его пока нет)

Галлюцинации – они критичны на этом этапе

Это из пушки по воробьям и тяжело контролировать Пока я это отложил, но использовал потом для перефразирования



Экстрактивная суммаризации предложений

Методы данного подхода характеризует наличие оценочной функции важности информационного блока. Ранжируя эти блоки по степени важности и выбирая ранее заданное их число, мы формируем итоговое резюме текста.

- → Graph based (TextRank, LexRank- на основе pagerank)
- → Fuzzy logic based
- → Topic Words (Luhn)
- → Latent Semantic Analysis Method (LSA)
- → Frequency-driven (Tf-IDF, KL Divergence)

 ${\bf Table~3} - {\bf Average~context~score~for~the~keyword~extraction~models~based~on~the~original~text}$

Method	Average context score
Textrank - BERT	0,5030
K-means - BERT	0,4727
K-means - TF-IDF	0,4555
Textrank - TF-IDF	0,4546
LSA	0,3893
Random baseline	0,3612



Про библиотеки

Тестил низкоуровневые реализации - требуют допиливания, хотя много и есть лекции

Нашел либу — совладал

from sumy.nlp.tokenizers import Tokenizer from sumy.summarizers.luhn import LuhnSummarizer from sumy.summarizers.text_rank import TextRankSummarizer from sumy.summarizers.lsa import LsaSummarizer from sumy.summarizers.lex_rank import LexRankSummarizer from sumy.summarizers.kl import KLSummarizer from sumy.nlp.stemmers import Stemmer

ИТМО AI TALENT HUB работа.ру



Результаты слепого тестирования

Команда голосовала и вышли в лидеры:

- → Пайплайн с sumy_TextRank
- → Пайплайн с sumy_LSA

Немного про них



Textrank

Оценить сходство между предложениями используя матрицу сходства, рассчитанную с помощью косинусного сходства. Матрица сходства затем используется в качестве весов для ребер графа.

Важным аспектом TextRank является то, что он не требует глубоких лингвистических знаний, аннотированных корпораций, специфичных для конкретной области или языка, что делает его легко переносимым на другие области, жанры или языки.

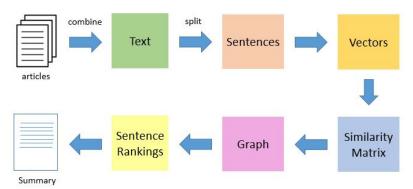


Textrank

- 1. Первым шагом будет конкатенация всего текста, содержащегося в вакансии.
- 2. Затем разделите текст на отдельные предложения.
- 3. На следующем этапе мы находим векторное представление (вставки слов) для каждого предложения.
- 4. Сходство между векторами предложений вычисляется и сохраняется в матрице.
- 5. Позже матрица сходства преобразуется в граф, где предложения являются вершинами, а оценки сходства ребрами, для вычисления диапазона предложений.
- 6. Наконец, определенное количество предложений с наилучшим рейтингом формирует окончательное резюме.

Weighted Graphs

$$WS(V_i) = (1 - d) + d * \sum_{V_j \in In(V_i)} \frac{w_{ji}}{\sum_{V_k \in Out(V_j)} w_{jk}} WS(V_j)$$



of two sentences with the length of each sentence. Formally, given two sentences S_i and S_j , with a sentence being represented by the set of N_i words that appear in the sentence: $S_i = w_1^i, w_2^i, ..., w_{N_i}^i$, the similarity of S_i and S_j is defined as:

$$Similarity(S_i, S_j) = \frac{|\{w_k | w_k \in S_i \& w_k \in S_j\}|}{log(|S_i|) + log(|S_j|)}$$



Latent Semantic Analysis (LSA)

LSA опирается на статистические методы для оценки скрытой семантической структуры данных. LSA строит латентное семантическое пространство, в котором документы и слова представлены в виде векторов.

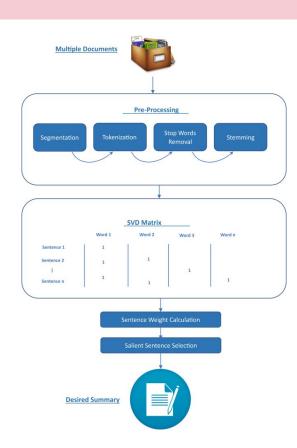
LSA использует математическую технику Singular Value Decomposition (SVD) для распознавания связей между различными терминами и понятиям.

Гонг и X. Лю (2001) предложили метод обобщения, который использует LSA для того для создания резюме на основе наиболее важных предложений.



Latent Semantic Analysis (LSA)

- 1. Предварительная обработка текста:
- Построение матрицы термов-документов:
 Строится матрица, где строки представляют термины (слова), а столбцы документы.
 В ячейках матрицы указывается частота встречаемости термов в каждом предложении или, возможно, более сложные меры веса, такие как TF-IDF.
- 3. Применение сингулярного разложения (SVD):
 - Матрица U представляет собой матрицу левых сингулярных векторов и содержит информацию о семантической структуре термов.
 - Матрица S диагональная матрица, содержащая сингулярные значения, отражающие важность скрытых семантических факторов.
 - Матрица V представляет собой матрицу правых сингулярных векторов и содержит информацию о семантической структуре документов.
- 4. Сокращение размерности: Это позволяет удалить шум и сохранить наиболее информативные и семантически значимые факторы.
- 5. Вычисление семантической близости: Используя усеченные матрицы U и S, можно вычислить близость между термами или документами





Yes! — результаты экстрактивный

пока 20к синтезированных для SFT

Вакансия

Требования: Строительная компания приглашает на работу вахтовым методом. Вахта на Север 60/30. Заработная плата 150 тыс. рублей. Обратите внимание: опыт работы в аналогичной должности строго ОБЯЗАТЕЛЕН. Оформление по ТК РФ, з/п 2 раза в месяц на карту. Работодатель предоставляет проживание, 3-разовое питание, спецодежду, обувь. Компенсация проезда Информация о работодателе: Строительная компания.

sumy_LexRank Строительная компания приглашает на работу вахтовым методом. Заработная плата 150 тыс. рублей. Обратите внимание. sumy_Luhn Строительная компания приглашает на работу вахтовым методом. опыт работы в аналогичной должности строго ОБЯЗАТЕЛЕН. Строительная компания.

sumy_KLdiv Строительная компания приглашает на работу вахтовым методом. Вахта на Север 60/30. з/п 2 раза в месяц на карту.

sumy_LSA Строительная компания приглашает на работу вахтовым методом. опыт работы в аналогичной должности строго ОБЯЗАТЕЛЕН. з<u>/</u>п 2 раза в месяц на карту.

sumy_TextRank Строительная компания приглашает на работу вахтовым методом. з/п 2 раза в месяц на карту. Работодатель предоставляет проживание.



Про модель перефразирования

Выбрали cointegrated/rut5-base-paraphraser

from transformers import T5ForConditionalGeneration, T5Tokenizer

MODEL_NAME = 'cointegrated/rut5-base-paraphraser'

model = T5ForConditionalGeneration.from_pretrained(MODEL_NAME)

tokenizer = T5Tokenizer.from_pretrained(MODEL_NAME)

Выбрали экстрактивные реализации от 200-300 символов

и перефразируем их в 150-200 символов

Настроил модель перефразирования

протестил - результат порадовал, но уже сильно дольше





Yes! — результаты перефразированных

Результаты

sumy_LSA Строительная компания приглашает на работу вахтовым методом. опыт работы в аналогичной должности строго ОБЯЗАТЕЛЕН. з/п 2 раза в месяц на карту.

para_LSA Компания "Строительная компания" приглашает вахтовиков на постоянную работу. 3/п не менее 2 раз в месяц. sumy_TextRank Строительная компания приглашает на работу вахтовым методом. з/п 2 раза в месяц на карту. Работодатель предоставляет проживание.

para_TextRank Компания строителей приглашает на вахту. 3/п от 2 раз в месяц. Работодателю предоставляется жилье.





Yes! — результаты перефразированных

20к + 20к* - 40к синтезированных для SFT

* мы уже плюсуем абстрактивный вариант

После дообучения LLM не должна хакнуть алгоритмы экстрактивной суммаризации, потому что мы использовали парафрайзер

убили 2 зайцев: сжимать и работать абстрактивно



Yes! — результаты всех

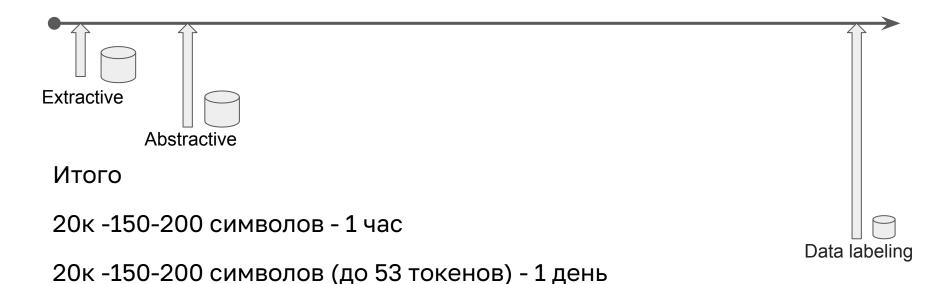
20к +20к+<mark>7к</mark>* - <mark>47к</mark> синтезированных для SFT

Со звездочкой это уже: ручками

Ничего интересного, только тяжелый труд



ДАТАСЕТ ДЛЯ SFT



7к - 150-200 символов (краусорс) - 1 месяц



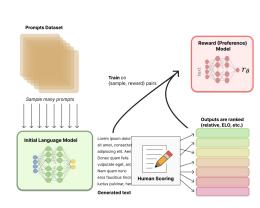
- Датасет составлен на основе HR домена
- Содержит большинство важной инфы с точки зрения работодательсоискатель
- Содержит экстрактивную, абстрактивную и ручную разметку

Позволяет дообучить через SFT любой трансформер



Что было дальше? Продакшн?

- 1. Модель после SFT генерирует датасет для RLHF
- 2. Этап RLHF
 - →показываем несколько саммари и даем окошко для своего
 - →вручную экспертами ранжируем 1-1.5 к саммари
 - →Сохраняем данные о выборе
 - →обучаем RM
- 3. Так устроили бизнес процессы, что можем использовать RLHF модель итеративно





Спасибо!



tg, inst: @space_apple



Никита Венедиктов

VİTMO

AI TALENT HUB

работа.ру



Краткое описание задачи RLHF и ее значимость

Reinforcement Learning from Human Feedback

обучение с подкреплением на основе человеческих предпочтений

ну это база - обратная реакция от пользователя

вот в GPT

